Metaheurísticas

Curso 2025/2026

Práctica 2
(3 semanas)

Enunciado

En muchos problemas de aprendizaje automático es necesario ajustar hiperparámetros, es decir, parámetros que controla el comportamiento del algoritmo de aprendizaje. El rendimiento del modelo depende, en gran medida, de estos valores. Sin embargo, encontrar la mejor combinación suele requerir explorar un espacio de búsqueda grande y complejo. Esta segunda práctica está orientada al desarrollo y aplicación de un algoritmo genético para la optimización de hiperparámetros de un modelo de aprendizaje automático. El objetivo es maximizar la precisión de clasificación sobre un conjunto de datos real.

Se utilizará como conjunto de datos el dataset Wine Quality, el cual contine mediciones físico-químicas de vinos junto con una evaluación de su calidad. Algunas de las características del vino son acidez fija, acidez volátil, cloruros, densidad, pH, etc. La variable objetivo es la variable *quality*, que indica la calidad del vino. Para simplificar el problema vamos a transformar el problema a un problema de clasificación binaria, de manera que si la calidad >= 6 el vino es bueno, y si la calidad < 6 el vino es malo. El dataset se encuentra en la siguiente URL:
https://archive.ics.uci.edu/ml/machine-learning-databases/wine-quality/winequality-red.csv

Vamos a considerar el modelo Random Forest de la librería scikit-learn. No hay que saber prácticamente nada de este modelo, de su funcionamiento por dentro. Hay que tomarlo como una caja negra que, entrenado con unos hiperparámetros y dado un conjunto de datos, te da una clasificación (vino bueno o vino malo) para esos datos. La API del modelo se encuentra en la siguiente URL:
https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html

Los genes deben tomar valores dentro de los siguientes rangos:

Parámetro	**Tipo**	**Rango**
n_estimators	entero	10 – 300
max_depth	entero	2 – 30
min_samples_split	entero	2 – 20
min_samples_leaf	entero	1 – 20
max_features	real	0.1 – 1.0
bootstrap	binario	0 / 1
criterion	categórico	0 = gini, 1 = entropy
class_weight	binario	0 = None, 1 = balanced
max_leaf_nodes	entero	10 – 200
min_impurity_decrease	real	0 – 0.1

El fitness de un individuo se calculará del siguiente modo:

1. Se construye un modelo Random Forest utilizando los hiperparámetros representados en el cromosoma.
2. Se aplica validación cruzada con 5 folds sobre el dataset.
3. En cada fold:
    a. el modelo se entrena con el 80% de los datos
    b. se evalúa con el 20% restante
4. El fitness será el accuracy medio obtenida en los 5 folds.

Código:

```
import pandas as pd
import numpy as np

from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import cross_val_score
from sklearn.model_selection import train_test_split


# cargar dataset
data = pd.read_csv("winequality-red.csv")

# convertir problema a clasificación binaria
data["quality"] = (data["quality"] >= 6).astype(int)

X = data.drop("quality", axis=1)
y = data["quality"]


def evaluate_solution(params):

    model = RandomForestClassifier(
        n_estimators=int(params[0]),
        max_depth=int(params[1]),
        min_samples_split=int(params[2]),
        min_samples_leaf=int(params[3]),
        max_features=float(params[4]),
        bootstrap=bool(params[5]),
        criterion="gini" if params[6] == 0 else "entropy",
        class_weight=None if params[7] == 0 else "balanced",
        max_leaf_nodes=int(params[8]),
        min_impurity_decrease=float(params[9]),
        random_state=42
    )

    scores = cross_val_score(model, X, y, cv=5, scoring="accuracy")

    return scores.mean()
```

Entregables

Los estudiantes deben entregar:

- Memoria de prácticas en pdf.
- Código fuente en Python con los algoritmos implementados. Puede usarse Google Colab, por lo que se entregaría el enlace público para acceder y ejecutar el código.

Criterios de Evaluación

- Comparación y Análisis (50%): Justificación de los métodos (idoneidad para el problema, bondades, debilidades, etc.), evaluación del rendimiento de los

algoritmos y discusión de los resultados obtenidos cuando se compara con Random Search y con Grid Search.

- Presentación del Informe y código (30%): Documentación estilo formal, con explicaciones claras de los algoritmos, y claridad en las explicaciones de la comparativa. Código con comentarios.
- Defensa (20%): Defensa de las propuestas realizadas y del informe de prácticas ante el profesor. Uso de material de apoyo para la defensa. Responder correctamente a las preguntas planteadas.